

TECH CHALLENGE — FASE 2

IADT — Inteligência Artificial e Data Transformation

Projeto 1 — entrega da Fase 2 do Tech Challenge

Otimização de diagnóstico de câncer de mama com Algoritmo Genético e LLM

Saúde e segurança da mulher — Wisconsin Breast Cancer Dataset

Participantes

Ana Clara Gouvêa Poubel

Rafael Evangelista da Silva

Samir Iago Souza Góes

Diego Justino Amaral de Souza

Data: 01/09/2026

Repositório Git: <https://github.com/SamirGoes/tech-challenge-fiap-fase2>

Este relatório descreve o **Projeto 1**, utilizado como entrega da **Fase 2** do Tech Challenge. O trabalho parte do notebook `notebooks/GA_HyperparametersOptimization.ipynb`. O ponto de partida é o modelo de Regressão Logística já treinado no dataset Wisconsin Breast Cancer (classificar tumor em maligno ou benigno).

1. O problema e o objetivo

O modelo classifica o tumor como **maligno** ou **benigno** com 30 medidas do núcleo celular. Na etapa anterior os hiperparâmetros foram escolhidos na mão / no padrão do scikit-learn.

Nesta fase o recorte é outro:

1. **Otimizar** os hiperparâmetros da **Regressão Logística** com um Algoritmo Genético escrito do zero (`src/ga_utils.py`).
2. **Comparar 3 configurações do GA** (mutação fixa, mutação adaptativa, mutação adaptativa + roleta) no mesmo holdout de teste.
3. **Explicar o resultado em português**, com o Claude, para um profissional de saúde — sem jargão de machine learning (`src/llm_utils.py`).
4. **Expor o modelo** numa API (FastAPI) e num front (Angular), com um **exame simplificado** de 10 medidas.

O dataset continua o mesmo: `data/data.csv` (569 amostras, 30 features + diagnóstico). Treino: 455 linhas. Teste: 114 linhas (20%, `random_state=42`). **O teste nunca entra na busca do GA** — só na avaliação final.

2. O que é o Algoritmo Genético neste projeto

Em vez de testar hiperparâmetros um a um, o GA mantém uma **população** de configurações e as faz evoluir:

Ideia	No nosso código
Indivíduo	um dicionário com <code>C</code> , <code>penalty</code> e <code>class_weight</code>
Fitness	$0,5 \cdot recall + 0,3 \cdot F1 + 0,2 \cdot accuracy$ (validação cruzada 5-fold só no treino)
Seleção	torneio (k=3) ou roleta
Crossover	uniforme: cada gene vem de um dos pais
Mutação	reamostra o gene; pode ser taxa fixa ou decaindo ao longo das gerações
Elitismo	os 2 melhores passam intactos

O **recall pesa mais** porque, em câncer, classificar um maligno como benigno (falso negativo) é o erro mais grave.

O loop de gerações é uma função só: `ga_utils.rodar_ga(...)`. Cada experimento no notebook só muda população, mutação e tipo de seleção.

Espaço de busca da Regressão Logística:

Gene	Valores
C	contínuo, de 0,01 a 10
penalty	11 ou 12
class_weight	None ou balanced


3. Os 3 experimentos

Todos na Regressão Logística, população **20**, **15** gerações, `seed=42`.

Experimento	O que muda	Hiperparâmetros encontrados
1 — padrão	Torneio + mutação fixa 20%	<code>C ≈ 0,037</code> , <code>penalty=11</code> , <code>class_weight=balanced</code>
2 — mutação adaptativa	Torneio + mutação 20% → 5%	mesmo indivíduo (<code>C ≈ 0,037</code> , <code>11</code> , <code>balanced</code>)
3 — adaptativa + roleta	Roleta + mutação 20% → 5%	mesmo indivíduo (<code>C ≈ 0,037</code> , <code>11</code> , <code>balanced</code>)

As curvas abaixo saem do notebook. Em todas, o melhor fitness sobe cedo (por volta da geração 5) e o elitismo segura esse valor até o fim.


Experimento 1 — torneio + mutação fixa 20%




A linha azul (melhor) chega perto de 0,995 e fica estável. A laranja (média da população) sobe com mais oscilação — a mutação fixa continua mexendo nos indivíduos.

Experimento 2 — torneio + mutação 20% → 5%

Convergência do GA — Regressão Logística, mutação adaptativa (pop=20, mutação=0.2)




Decaimento da taxa de mutação




Mesmo salto na fitness. O gráfico da direita mostra a taxa de mutação caindo em linha reta, de 20% para 5%.

Experimento 3 — roleta + mutação 20% → 5%

Convergência do GA — Regressão Logística, mutação adaptativa (pop=20, mutação=0.2)



Decaimento da taxa de mutação



A mutação decai igual ao Experimento 2. A seleção por roleta muda o caminho, mas o melhor indivíduo no fim foi o mesmo.

Na última execução, as três buscas chegaram no **mesmo indivíduo**. Isso não é “erro”: com a mesma semente e um espaço pequeno, o GA encontra uma região boa cedo e o elitismo a preserva.

4. Resultado: original vs. otimizado

Holdout de teste (114 amostras, nunca visto pelo GA). Números do notebook:

Versão	Accuracy	Precision	Recall	F1
Original (padrão sklearn)	0,9737	0,9756	0,9524	0,9639
Experimento 1 — GA (mutação fixa)	0,9912	0,9767	1,0000	0,9882
Experimento 2 — mutação adaptativa	0,9912	0,9767	1,0000	0,9882
Experimento 3 — adaptativa + roleta	0,9912	0,9767	1,0000	0,9882

Leitura simples

- O GA **melhorou** o baseline: recall de 95,2% para **100%** e acurácia de 97,4% para **99,1%**.
- As três variações empataram no teste porque acharam a mesma configuração.

- Nenhuma versão piorou o original.
- O modelo escolhido para LLM, API e front é o da **Regressão Logística otimizada (Experimento 1)**.

Tabela salva em `experiments/results/comparison_table.csv`.


5. Feature importances — exame simplificado

O exame original pede **30 números** do núcleo da célula (tamanho, textura, contorno etc.). Preencher tudo isso na prática é trabalhoso. Depois de treinar o modelo, a pergunta é outra: **quais medidas ele realmente usou** para dizer se o tumor é maligno ou benigno?

O gráfico abaixo é essa resposta. Quatro medidas concentraram quase toda a decisão:

- o **tamanho máximo** do núcleo (`radius_worst`)
- o quão **irregular** é o contorno (`concave points_worst` e `concave points_mean`)
- a **textura** (`texture_worst`)

As outras entram na lista das 10, mas neste modelo quase não pesaram. Com só essas 10 medidas o teste ficou no **mesmo patamar** do exame completo: **99% de acerto** e **nenhum caso maligno classificado como benigno**. Por isso a aplicação pede o exame simplificado, e não as 30 colunas.



A lista das 10 **não fica fixa no formulário**. Ela sai do ranking do modelo. Se o notebook rodar de novo e a ordem mudar, a tela acompanha.

6. Interpretação com LLM

O modelo devolve só um rótulo (**maligno** ou **benigno**) e uma porcentagem. Isso não ajuda o profissional de saúde a entender o caso.

Pedimos então ao **Claude** para escrever um texto curto em português, no tom de um laudo de triagem.

Regras simples:

- ele **não diagnostica** — só explica o que o modelo já calculou
- se o resultado for **positivo**, fala a chance de ser **maligno**; se for **negativo**, fala a chance de ser **benigno** (não o “resto” da porcentagem)
- quando os números vieram altos, cita tamanho, textura e contorno
- fecha avisando que **não substitui** o diagnóstico médico

Não existe nota automática do tipo “o laudo tirou 9”. A avaliação é ler e conferir: o texto bate com o número do modelo? inventou algum exame? usou jargão de machine learning? Se escapar, ajustamos o pedido feito ao Claude.

Exemplo no teste (caso maligno): o texto saiu **positivo, 99% de chance de ser maligno**, citou o raio grande e os pontos côncavos do contorno, e fechou dizendo que é triagem.

7. API e front-end

O notebook exporta o modelo e o ranking. A API **carrega o que já foi treinado** — não treina de novo a cada requisição.

Rotas que o front usa:

Endpoint	Função
GET /predict/simplificado/features	lista as 10 medidas do JSON
POST /predict/simplificado	classifica 1 exame e devolve o laudo
POST /predict/lote/simplificado	mesmo fluxo para um CSV

Ainda existem /predict e /predict/lote com as 30 features; a tela atual mostra **só o simplificado**.

No laudo da interface, a barra usa a chance da classe prevista (`probabilidade`): caso negativo mostra, por exemplo, **78% de chance de ser benigno**, não os 22% de maligno.

Como rodar localmente:

```
python -m uvicorn api.main:app --reload
# http://127.0.0.1:8000/docs

cd frontend
npm start
# http://localhost:4200
```

A chave do Claude fica no `.env` (`ANTHROPIC_API_KEY`). Sem ela o modelo classifica; o laudo não é gerado.

8. Nuvem (item extra)

O modelo otimizado foi empacotado para AWS, com infraestrutura em Terraform (`terraform/`):

- **Lambda** (imagem Docker) + autoscaling
- **Function URL** como HTTPS público
- **SSM Parameter Store** para a chave da Anthropic
- **CloudWatch Logs**

Detalhes em [docs/ARCHITECTURE.md](#) e [terraform/README.md](#). A API foi validada localmente com `uvicorn`. O `terraform apply` na conta AWS fica para o momento do deploy da demo.

9. Desafios e o que aprendemos

- **Não vazar o teste no fitness.** Uma versão antiga avaliava o indivíduo direto no `X_test`. Isso inflaria o resultado. Corrigimos para `StratifiedKFold` só no treino.
 - **Holdout pequeno (114 linhas).** Um acerto a mais ou a menos já mexe quase 1 ponto percentual. Por isso duas buscas “quase iguais” podem empatar no teste — e, nesta execução, as três acharam o mesmo indivíduo.
 - **LLM copiar o número errado.** O prompt antigo pedia sempre “chance de ser maligno”. No caso benigno a barra mostrava 22%. Ajustamos para falar a chance da **classe prevista**.
 - **Lista do exame simplificado viva.** Se a lista ficasse hardcoded no Angular, o front desencontraria do notebook. O ranking sai do JSON.
-

10. Conclusão

O GA melhorou a Regressão Logística no holdout (recall 95,2% → 100%). As três configurações de operadores, nesta semente, chegaram na mesma solução. O modelo aponta as 10 medidas que mais pesaram; a API e o front montam o exame simplificado a partir desse arquivo. A LLM só explica, em português, o que o modelo já decidiu. É **triagem automática** — não substitui diagnóstico médico.

Encadeamento: **GA escolhe o modelo → o modelo aponta as 10 medidas → JSON alimenta API e front → Claude escreve o laudo.**

11. Entregáveis

Item	Local / observação
Repositório Git	https://github.com/SamirGoes/tech-challenge-fiap-fase2
Notebook	https://github.com/SamirGoes/tech-challenge-fiap-fase2/blob/main/notebooks/GA_HyperparametersOptimization.ipynb
Aplicação (AWS)	<i>inserir a URL pública da API na AWS (usada no vídeo)</i>
Vídeo (até 15 min)	<i>inserir o link do YouTube/Vimeo depois de publicar</i>

Como executar: `git clone` do repositório → `pip install -r requirements.txt` → `jupyter notebook notebooks/GA_HyperparametersOptimization.ipynb`